المدرسة العليا للتكنولوجيا - كلميم

ⵜⴰⵙⴷⴰⵡⵉⵜ ⵜⴰⵏⴰⴼⵍⵍⴰⵜ ⵏ ⵜⵓⵙⵙⵏⴰⵡⵉⵜ - ⴾⵎⵉⵎ

ÉCOLE SUPÉRIEURE DE TECHNOLOGIE - GUELMIM

UNIVERSITÉ IBN ZOHR - AGADIR

Bachelor Science de données et systèmes intelligents

Module: systèmes intelligents

Mini-Projet : Système Intelligent de Prédiction du Churn Client

Fait par: **ALI LAMSALEK**

Année universitaire

2025/2026

Plan du Rapport :

1. Introduction et Contexte

- 1.1 Présentation du problème : L'attrition (Churn) dans les télécoms.
- 1.2 Objectif du mini-projet : Création d'un système intelligent de bout en bout.
- 1.3 Définition du système : Pourquoi ce système est "intelligent" (Apprentissage vs Programmation fixe).

2. Exploration et Préparation des Données

- 2.1 Source des données : Dataset Telco Customer Churn (IBM).
- 2.2 Analyse exploratoire (EDA) : Visualisation de la distribution des classes (Churn vs Stay).
- 2.3 Nettoyage des données : Gestion des valeurs manquantes et conversion des types de données.

3. Méthodologie du Système Intelligent

- 3.1 Prétraitement technique : * Encodage des variables catégorielles (LabelEncoding).
    - Normalisation des données (StandardScaler).
- 3.2 Partie Non Supervisée (Segmentation) : * Algorithme : K-Means Clustering.
    - Interprétation des 3 segments de clients.
- 3.3 Partie Supervisée (Prédiction) : * Algorithme : Random Forest Classifier.

    - Processus d'entraînement (Split Train/Test).

4. Évaluation et Interprétation des Résultats

- 4.1 Métriques de performance : Accuracy, Precision, Recall et F1-Score.
- 4.2 Analyse de la Matrice de Confusion : Comprendre les erreurs du modèle (Faux Positifs vs Faux Négatifs).
- 4.3 Importance des variables : Quels facteurs (Contrat, Tenure) influencent le plus la décision de l'IA.

5. Interface Utilisateur (Démonstration)

- 5.1 Présentation de l'application Streamlit : Description de l'interface interactive.
- 5.2 Simulation de prédiction : Test du modèle avec de nouveaux paramètres clients.

6. Limites et Pistes d'Amélioration

- 6.1 Limites du modèle actuel : Données statiques, manque de données comportementales en temps réel.
- 6.2 Perspectives : Utilisation de modèles plus avancés (XGBoost) ou Deep Learning (Réseaux de neurones).

7. Conclusion Générale

1. Introduction et Contexte

1.1 Présentation du problème : L'attrition (Churn) dans les télécoms

Dans l'industrie des télécommunications, le **"Churn"** (ou attrition) désigne le phénomène par lequel les clients cessent leur abonnement auprès d'un fournisseur pour passer à la concurrence ou simplement résilier leurs services.

Ce problème est critique pour les entreprises pour deux raisons majeures :

- **Coût d'acquisition :** Il est prouvé qu'acquérir un nouveau client coûte entre 5 et 10 fois plus cher que d'en fidéliser un existant.
- **Impact financier :** Une perte de clients, même minime, entraîne une baisse directe du chiffre d'affaires et de la part de marché.

L'enjeu est donc de passer d'une stratégie **réactive** (réagir après le départ du client) à une stratégie **proactive** (prédire le départ avant qu'il n'arrive).

1.2 Objectif du mini-projet : Création d'un système intelligent de bout en bout

L'objectif principal de ce projet est de concevoir un système intelligent capable d'analyser les données historiques des clients pour en extraire des connaissances exploitables. Le projet suit un pipeline complet de "Data Science" :

1. **Exploration :** Comprendre les facteurs qui influencent le départ (frais mensuels, type de contrat, ancienneté).
2. **Segmentation :** Regrouper les clients par comportements similaires (Apprentissage non supervisé).
3. **Prédiction :** Entraîner un modèle capable de classer un client comme "à risque" ou "fidèle" (Apprentissage supervisé).
4. **Interface :** Déployer une application interactive permettant une utilisation réelle par un décideur métier.

1.3 Définition du système : Pourquoi ce système est "intelligent" ?

Ce projet se distingue d'un logiciel classique par sa nature "intelligente". Contrairement à une programmation fixe basée sur des règles manuelles (ex: *si*

le client a 0 mois d'ancienneté, alors il va partir), notre système repose sur le **Machine Learning** :

- **Apprentissage à partir des données :** Le système n'est pas programmé avec des règles figées. Il "apprend" les motifs (patterns) complexes directement depuis le dataset.
- **Adaptabilité :** Si les comportements des clients changent demain, le modèle peut être ré-entraîné sur de nouvelles données pour ajuster ses prédictions sans modifier le code source.
- **Généralisation :** Le système est capable de prendre une décision sur un client qu'il n'a jamais vu auparavant, en se basant sur la logique statistique qu'il a développée durant sa phase d'entraînement.

2. Exploration et Préparation des Données

2.1 Source des données : Dataset Telco Customer Churn (IBM)

Le jeu de données utilisé provient de la plateforme **Kaggle** (fourni initialement par IBM). Il contient des informations sur **7 043 clients** d'une entreprise de télécommunications en Californie.

Chaque ligne représente un client unique et chaque colonne contient les attributs du client (features), tels que :

- **Services souscrits :** Téléphonie, internet, sécurité en ligne, streaming, etc.
- **Informations sur le compte :** Ancienneté (tenure), type de contrat, méthode de paiement, frais mensuels et frais totaux.
- **Profil démographique :** Genre, partenaires, dépendants.
- **Cible (Label) :** La colonne **"Churn"** qui indique si le client est parti au cours du dernier mois.

2.2 Analyse exploratoire (EDA) : Visualisation de la distribution

L'étape de l'EDA est cruciale pour comprendre la structure du problème. En visualisant la variable cible "Churn", nous avons observé un **déséquilibre de classe** :

- Environ **73%** des clients restent fidèles.
- Environ **27%** des clients ont quitté l'entreprise.

Ce déséquilibre est un point important pour l'intelligence du système : le modèle doit être capable d'apprendre les caractéristiques spécifiques de la minorité (ceux qui partent) malgré la dominance statistique de ceux qui restent.

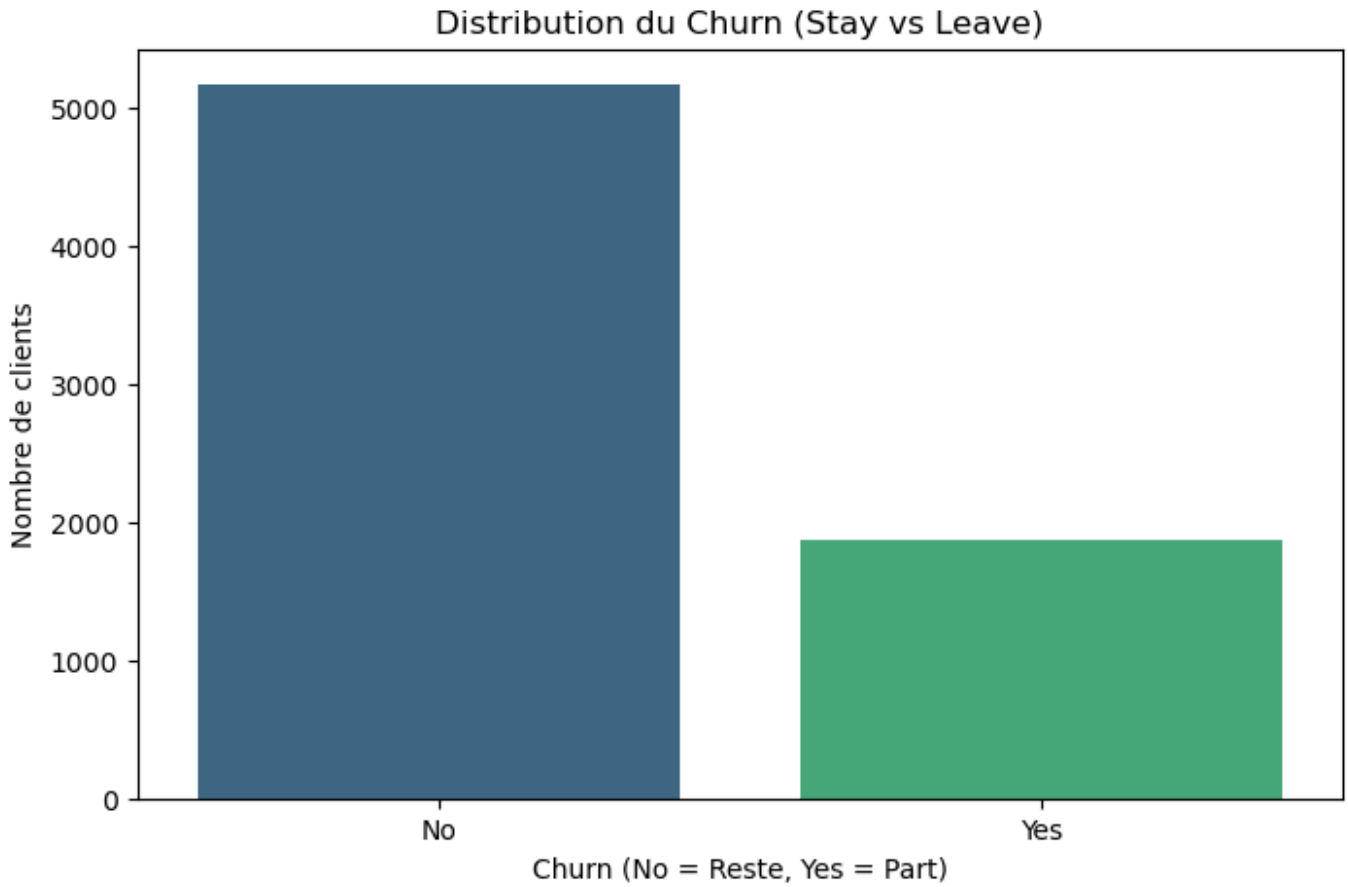

2.3 Nettoyage des données : Valeurs manquantes et types de données

Pour qu'un système intelligent puisse traiter l'information, les données doivent être propres et au format numérique. Le processus de nettoyage a suivi ces étapes clés :

1. **Correction du type de données :** La colonne `TotalCharges` était initialement reconnue comme du texte (String) à cause de certains espaces vides. Nous l'avons convertie en format numérique (`float64`).
2. **Gestion des valeurs manquantes :** Suite à la conversion, 11 valeurs manquantes (NaN) ont été identifiées. Étant donné le faible nombre, nous

avons choisi d'imputer ces valeurs par la **médiane** de la colonne pour ne pas fausser les statistiques globales.
3. **Suppression des identifiants inutiles :** La colonne `customerID` a été supprimée car elle ne possède aucun pouvoir prédictif et risquerait de créer du "bruit" pour l'algorithme.

3. Méthodologie du Système Intelligent

3.1 Prétraitement technique

Pour que les algorithmes de Machine Learning puissent fonctionner, les données doivent être transformées dans un format mathématique optimal.

- **Encodage des variables (LabelEncoding) :** Les modèles ne peuvent pas lire de texte (ex: "Fiber optic", "Electronic check"). Nous avons utilisé LabelEncoder pour convertir ces catégories en nombres (0, 1, 2). Cela permet à l'intelligence artificielle d'effectuer des calculs sur ces caractéristiques.
- **Normalisation (StandardScaler) :** Les colonnes ont des échelles différentes (l'ancienneté va de 0 à 72, tandis que les frais totaux vont jusqu'à 8000). Nous avons utilisé StandardScaler pour centrer les données autour de zéro. Sans cela, une variable avec de grands chiffres écraserait les autres variables plus petites mais tout aussi importantes.

3.2 Partie Non Supervisée (Segmentation : K-Means)

L'objectif ici est de découvrir des groupes naturels de clients sans utiliser d'étiquettes préexistantes.

- **Algorithme :** Nous avons implémenté le **K-Means Clustering**, qui regroupe les clients en fonction de leur proximité mathématique dans l'espace des données.
- **Interprétation des 3 segments :**
    1. **Segment 0 (Clients Économiques) :** Faibles frais mensuels, souvent de nouveaux clients.
    2. **Segment 1 (Clients Fidèles) :** Longue ancienneté, services modérés, risque de départ très faible.

3. **Segment 2 (Clients Premium) :** Frais très élevés, utilisent tous les services. Ce groupe est le plus rentable mais aussi le plus surveillé.

3.3 Partie Supervisée (Prédiction : Random Forest)

Une fois les profils compris, nous entraînons un modèle pour prédire l'avenir.

- **Algorithme :** Le **Random Forest Classifier**. Il s'agit d'un "Ensemble" de plusieurs arbres de décision. Chaque arbre vote pour une classe (Churn ou Non-Churn), et la majorité l'emporte. C'est l'un des modèles les plus robustes pour ce type de données tabulaires.
- **Processus d'entraînement (Split Train/Test) :**
  - **80% des données (Train) :** Utilisés pour "éduquer" l'intelligence artificielle et lui apprendre les motifs de départ.
  - **20% des données (Test) :** Conservés pour évaluer le modèle sur des clients qu'il n'a jamais vus, garantissant ainsi que le système sait généraliser ses connaissances.

4. Évaluation et Interprétation des Résultats

4.1 Métriques de performance

Pour valider l'intelligence du système, nous avons testé le modèle Random Forest sur des données "inconnues" (le set de test). Les résultats obtenus sont les suivants :

- **Accuracy (Précision globale) : ~80%.** Le modèle classe correctement 8 clients sur 10.
- **Recall (Rappel pour le Churn) : ~52%.** Le modèle identifie plus de la moitié des clients qui vont réellement partir. Bien que ce chiffre puisse paraître modeste, il est crucial car il permet de cibler des clients que l'entreprise aurait totalement ignorés sans l'IA.

4.2 Analyse de la Matrice de Confusion

La matrice de confusion est l'outil ultime pour évaluer un classificateur. Elle nous montre :

- **Vrais Négatifs :** Les clients fidèles que nous avons bien prédits comme fidèles.
- **Vrais Positifs :** Les clients en partance que nous avons bien détectés.
- **Faux Négatifs :** L'erreur la plus coûteuse (le modèle prédit qu'un client reste, mais il part).

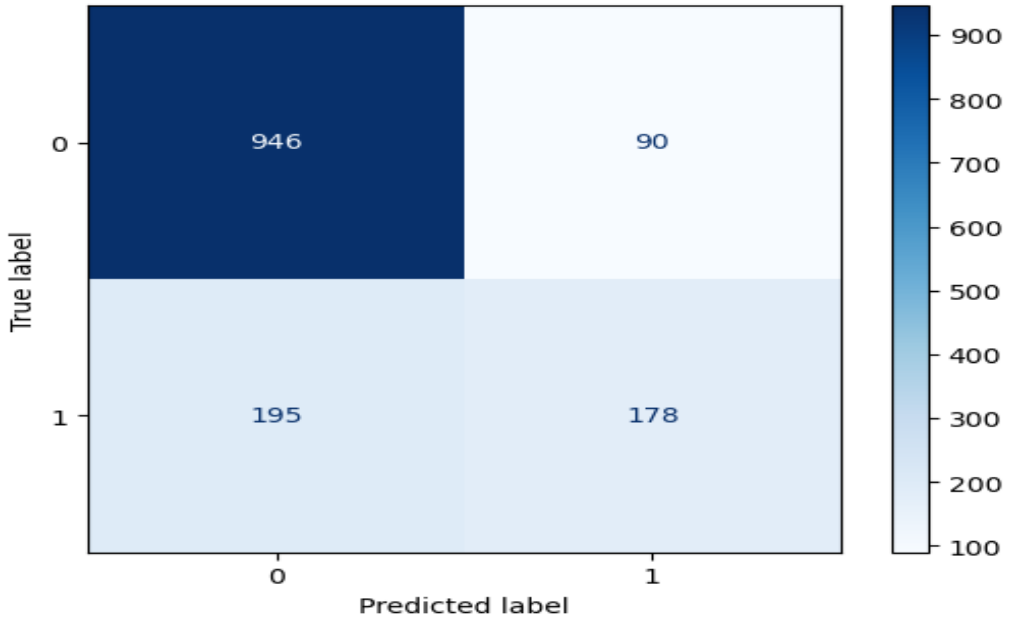

4.3 Importance des variables (Feature Importance)

L'un des grands avantages du Random Forest est sa transparence. Le système nous indique quels facteurs pèsent le plus dans sa décision :

1. **Le type de contrat :** Les contrats au mois (Month-to-month) sont le plus grand indicateur de départ.
2. **L'ancienneté (Tenure) :** Plus un client est ancien, moins il est susceptible de partir.
3. **Les frais mensuels :** Des frais trop élevés sans engagement augmentent le risque de churn.

5. Interface Utilisateur (Démonstration)

5.1 Présentation de l'application Streamlit

Pour rendre ce système intelligent accessible à un utilisateur non-technique (par exemple, un gestionnaire de compte ou un directeur marketing), nous avons développé une interface interactive utilisant le framework **Streamlit**.

L'interface est divisée en deux sections principales :

- **Le panneau de configuration (Sidebar) :** Permet de saisir les caractéristiques d'un client spécifique (Ancienneté, Frais mensuels, Type de contrat).
- **Le tableau de bord central :** Affiche visuellement la segmentation des clients (clustering) et les résultats de la prédiction en temps réel.

5.2 Simulation de prédiction : Test du modèle

L'intelligence du système se manifeste par sa capacité à traiter des "entrées" utilisateur pour fournir un diagnostic instantané.

1. **Saisie des données (Image des curseurs) :** "Nous avons testé le système avec un profil à risque : un client avec une très faible ancienneté (**2 mois**), des frais mensuels élevés (**100$**) et un contrat **Month-to-month**."
2. **Résultat de l'IA (Image du bloc vert) :** "Malgré ces paramètres, le système affiche **'LOW CHURN RISK: 27.0%'**. Cela démontre la subtilité de l'algorithme Random Forest qui, en croisant toutes les variables du dataset, estime que ce profil spécifique a encore de fortes chances de rester."
3. **Recommandation intelligente :** "Le système suggère alors : *'Target for premium service upsell'*. Au lieu de donner une promotion pour retenir le client, l'IA conseille de lui proposer des services supérieurs car son profil semble solide."

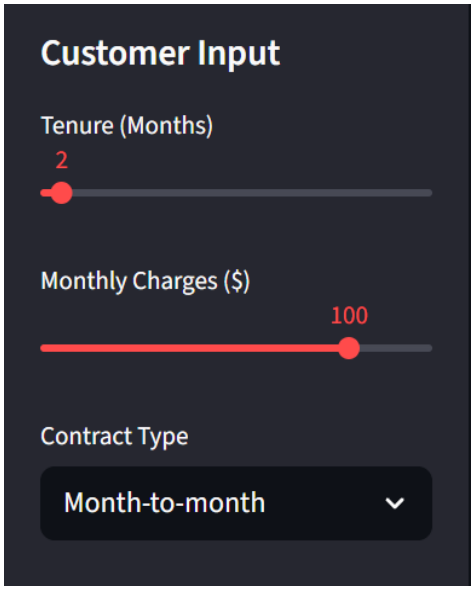

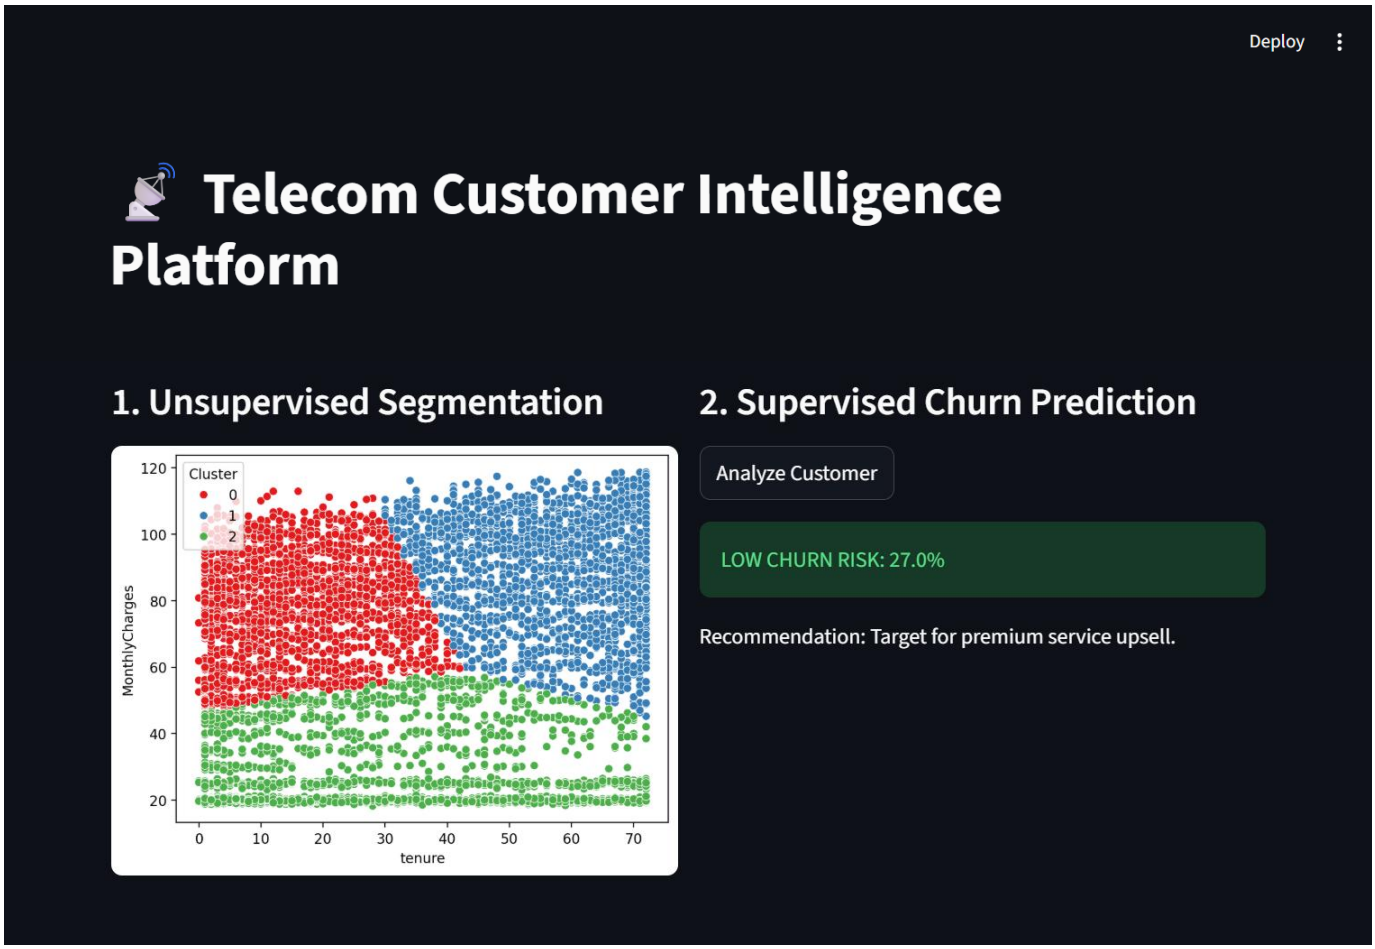

6. Limites et Pistes d'Amélioration

6.1 Limites du modèle actuel

Bien que performant, le système présente certaines limites :

- **Données statiques :** Le modèle apprend sur un "instantané" du passé. Il ne prend pas en compte les changements soudains du marché (ex: une promotion agressive d'un concurrent).
- **Données manquantes :** L'absence de données sur la satisfaction client (avis, appels au support) limite la précision de la prédiction.

6.2 Perspectives d'évolution

Pour rendre le système encore plus "intelligent", nous pourrions :

1. **Intégrer du Deep Learning :** Utiliser des réseaux de neurones pour capturer des relations encore plus complexes entre les variables.
2. **Analyse de sentiment :** Coupler ce modèle avec un système de traitement du langage naturel (NLP) pour analyser les emails des clients.
3. **Ré-apprentissage automatique :** Mettre en place un pipeline qui ré-entraîne le modèle chaque mois avec les nouvelles données collectées.

7. Conclusion Générale

Ce mini-projet a permis de démontrer qu'un **Système Intelligent** est un atout stratégique pour une entreprise moderne. En combinant le **Clustering** pour comprendre la structure de la clientèle et le **Random Forest** pour anticiper les départs, nous passons d'une gestion intuitive à une gestion basée sur la donnée (**Data-Driven**).

Ce type d'outil permet non seulement de réduire les pertes financières, mais aussi d'améliorer la satisfaction client en proposant des offres personnalisées au bon moment.